

Confiabilidad, Sesgo, Explicabilidad y Uso Responsable

Modelos Fundacionales y Sistemas Multimodales

Material de lectura para el curso MCC225

IA Generativa y Aprendizaje Multimodal

Índice

1. Propósito del documento	3
2. Contexto académico de MCC225	3
3. De la evaluación técnica a la confiabilidad	3
3.1. Evaluación no es lo mismo que confiabilidad	3
3.2. Tres niveles de análisis	4
4. Fuentes base de la Semana 9	4
5. Modelos fundacionales confiables y responsables	5
5.1. La responsabilidad como propiedad sistémica	5
5.2. Dimensiones principales	5
6. Explicabilidad e interpretabilidad en MLLMs	6
6.1. Diferencia entre explicar e interpretar	6
6.2. Explicabilidad de datos	6
6.3. Explicabilidad del modelo	6
6.4. Explicabilidad en inferencia	7
7. Sesgo y fairness en sistemas multimodales	7
7.1. Qué significa sesgo en multimodalidad	7
7.2. FMBench como caso de alto impacto	7
7.3. Métricas de fairness	7
8. Confianza multimodal: verdad, robustez, seguridad, fairness y privacidad	8
8.1. El problema de la confianza multimodal	8
8.2. Riesgos cross-modal	8
9. NIST AI RMF Generative AI Profile	8
9.1. Gestión de riesgos para IA generativa	8
9.2. Funciones del marco	9
10.OECD AI Principles	9
10.1. Principios para IA confiable	9
11.ISO/IEC 42001:2023 y sistema de gestión de IA	9
11.1. De buenas intenciones a sistema de gestión	9
11.2. Aplicación a trabajos integradores	10
12.EU AI Act 2024/1689	10
12.1. Enfoque basado en riesgo	10
12.2. Traducción pedagógica	10

13. Pipeline responsable para proyectos multimodales	11
13.1. Fase 1: definición de alcance	11
13.2. Fase 2: documentación de datos	11
13.3. Fase 3: evaluación de desempeño	11
13.4. Fase 4: evaluación de confiabilidad	11
13.5. Fase 5: mitigación y reevaluación	11
14. Matriz de riesgos para MCC225	11
15. Criterios mínimos de calidad responsable	12
15.1. Criterio 1: alcance explícito	12
15.2. Criterio 2: evidencia separada por dimensión	12
15.3. Criterio 3: análisis de error con severidad	12
15.4. Criterio 4: limitaciones no decorativas	13
15.5. Criterio 5: trazabilidad	13
16. Checklist para el informe del estudiante	13
17. Errores conceptuales frecuentes	13
17.1. Confundir desempeño con confiabilidad	13
17.2. Usar explicaciones como decoración	13
17.3. Declarar que no hay sesgo sin medirlo	13
17.4. Tratar la regulación como un anexo irrelevante	13
18. Propuesta de actividad para la Semana 9	14
18.1. Objetivo	14
18.2. Entregables	14
18.3. Criterio de aprobación	14
19. Relación con el trabajo integrador	14
20. Conclusión	14
A. Glosario breve	15
B. Referencias	15

1. Propósito del documento

Este documento presenta una lectura técnica para la Semana 9 de MCC225 sobre confiabilidad, sesgo, explicabilidad y uso responsable de modelos fundacionales y sistemas multimodales. La lectura complementa la Semana 8, dedicada a evaluación, métricas, reproducibilidad y análisis de error, desplazando ahora el foco desde la medición del desempeño hacia la gestión de riesgos, la transparencia, la equidad, la gobernanza y la responsabilidad académica en el uso de sistemas multimodales.

El objetivo no es convertir al estudiante en especialista legal ni en auditor profesional de inteligencia artificial. El objetivo es que pueda razonar con rigor sobre cuándo un sistema multimodal puede considerarse confiable dentro de un alcance definido, qué tipos de sesgo debe buscar, qué significa explicar una predicción multimodal, qué evidencia mínima debe presentar y qué afirmaciones debe evitar cuando el experimento no las respalda.

La lectura usa ocho fuentes principales: *Reliable and Responsible Foundation Models: A Comprehensive Survey*, *Explainable and Interpretable Multimodal Large Language Models: A Comprehensive Survey*, *FMBench: Benchmarking Fairness in Multimodal Large Language Models on Medical Tasks*, *Unveiling Trust in Multimodal Large Language Models: Evaluation, Analysis, and Mitigation*, *NIST AI RMF Generative AI Profile*, *OECD AI Principles*, *ISO/IEC 42001:2023* y el *EU AI Act 2024/1689*. En conjunto, estas fuentes permiten conectar investigación técnica, evaluación responsable, marcos de gobernanza y obligaciones de documentación.

2. Contexto académico de MCC225

MCC225 estudia sistemas que integran texto, imagen, audio y video mediante modelos generativos, arquitecturas multimodales, embeddings compartidos, mecanismos de atención, alineamiento entre modalidades y evaluación experimental. En este contexto, la confiabilidad no es una propiedad abstracta ni puramente declarativa. Un sistema es confiable solo en relación con una tarea, una población, un conjunto de datos, una distribución de entrada, un entorno de uso, un nivel de riesgo y una forma de supervisión humana.

Por ejemplo, un modelo visión-lenguaje puede ser útil para describir imágenes educativas, pero no por ello debe usarse sin validación en medicina, seguridad, justicia o selección laboral. También puede reconocer objetos comunes y, al mismo tiempo, fallar en escenas con texto pequeño, imágenes borrosas, objetos raros, lenguaje local, ambigüedad cultural o preguntas que exigen razonamiento causal. La confiabilidad exige reconocer esta diferencia entre demostración, evaluación y despliegue responsable.

Desde el punto de vista del curso, esta lectura debe servir como base para:

1. evaluar riesgos en proyectos multimodales,
2. documentar sesgos y limitaciones,
3. construir matrices de error y riesgo,
4. justificar decisiones de diseño experimental,
5. incorporar explicabilidad sin caer en explicaciones decorativas,
6. formular conclusiones responsables en el trabajo integrador.

3. De la evaluación técnica a la confiabilidad

3.1. Evaluación no es lo mismo que confiabilidad

La evaluación técnica responde preguntas como: qué exactitud obtuvo el modelo, qué Recall@K alcanzó, cuántos errores cometió, qué benchmark se usó o cuál fue el costo computacional. La

confiabilidad exige una pregunta más amplia: si el sistema falla, quién puede verse afectado, qué tan severo es el error, si la falla es detectable, si existe supervisión humana, si hay trazabilidad de la decisión y si el usuario final entiende las limitaciones.

Un sistema multimodal puede tener buen desempeño promedio y, aun así, ser poco confiable si presenta fallas sistemáticas en subgrupos, si inventa evidencia visual, si no distingue incertidumbre, si filtra información sensible, si depende de datos no documentados o si se presenta como más capaz de lo que realmente es.

3.2. Tres niveles de análisis

Para MCC225 conviene separar tres niveles:

Modelo	Arquitectura, datos de entrenamiento, parámetros, capacidades, alucinaciones, robustez y sesgos internos.
Sistema	Pipeline completo: preprocesamiento, prompts, recuperación externa, filtros, interfaz, logs, evaluación y monitoreo.
Uso	Contexto de aplicación, usuarios, población afectada, supervisión, consecuencias de error, obligaciones de documentación y comunicación.

Una lectura responsable debe evitar atribuir al modelo propiedades que pertenecen al sistema completo. Por ejemplo, un benchmark puede medir un modelo aislado, pero un producto final puede incluir recuperación aumentada, herramientas externas, filtros de seguridad, compresión de imágenes y postprocesamiento. La confiabilidad debe analizar todo el flujo.

4. Fuentes base de la Semana 9

Tabla 1: Fuentes centrales para la lectura de la Semana 9

Fuente	Papel dentro de la lectura
<i>Reliable and Responsible Foundation Models</i>	Marco amplio para conectar sesgo, seguridad, privacidad, incertidumbre, explicabilidad, distribución fuera de entrenamiento, alucinaciones, alineamiento y detección de contenido generado por IA.
<i>Explainable and Interpretable MLLMs</i>	Base técnica para distinguir explicabilidad e interpretabilidad en modelos multimodales, incluyendo análisis de datos, componentes internos, entrenamiento e inferencia.
<i>FMBench</i>	Caso de estudio para fairness en tareas médicas multimodales, con atributos demográficos y métricas que combinan desempeño y equidad.
<i>Unveiling Trust in MLLMs</i>	Taxonomía de confianza multimodal que conecta veracidad, robustez, seguridad, fairness, privacidad, riesgos cross-modal y estrategias de mitigación.
<i>NIST AI RMF Generative AI Profile</i>	Marco operativo para gestionar riesgos de IA generativa mediante gobernanza, mapeo, medición y gestión de riesgos durante el ciclo de vida.
<i>OECD AI Principles</i>	Principios internacionales para IA confiable, centrada en derechos humanos, transparencia, robustez, responsabilidad e innovación inclusiva.

Fuente	Papel dentro de la lectura
ISO/IEC 42001:2023	Estándar de sistema de gestión de IA para organizar políticas, roles, evaluación de riesgos, documentación, operación, monitoreo y mejora continua.
EU AI Act 2024/1689	Marco regulatorio basado en riesgo, relevante para transparencia, documentación técnica, supervisión humana, gobernanza y obligaciones de sistemas de IA.

5. Modelos fundacionales confiables y responsables

5.1. La responsabilidad como propiedad sistémica

Reliable and Responsible Foundation Models: A Comprehensive Survey plantea que los modelos fundacionales modernos, incluidos LLMs, MLLMs, modelos generativos de imagen y modelos generativos de video, se usan en dominios como medicina, educación, ciencia, finanzas y derecho. Por ello, la pregunta por responsabilidad no se limita a evitar errores visibles. Incluye sesgo, fairness, seguridad, privacidad, incertidumbre, explicabilidad, cambios de distribución, alucinaciones, alineamiento, detección de contenido generado y limitaciones de uso.

La idea central para MCC225 es que responsabilidad no es una métrica única. Es una propiedad sistémica que emerge de decisiones de datos, arquitectura, entrenamiento, evaluación, documentación, despliegue y monitoreo. Un modelo puede mejorar en una dimensión y degradarse en otra. Por ejemplo, una técnica de alineamiento puede reducir respuestas problemáticas, pero también aumentar rechazos innecesarios o disminuir utilidad en ciertas tareas. Una evaluación responsable debe explicitar esos trade-offs.

5.2. Dimensiones principales

Tabla 2: Dimensiones de confiabilidad y responsabilidad

Dimensión	Pregunta orientadora	Evidencia esperada en MCC225
Fairness	¿El sistema presenta diferencias sistemáticas entre grupos o contextos?	Métricas por subgrupo, ejemplos cualitativos y discusión de cobertura de datos.
Privacidad	¿El sistema puede exponer datos sensibles o memorizar información no autorizada?	Política de datos, anonimización, restricciones de entrada y salida.
Seguridad	¿El sistema puede ser inducido a producir salidas dañinas o no autorizadas?	Pruebas adversariales controladas y límites de uso.
Incetidumbre	¿El sistema comunica cuándo no sabe o cuándo la evidencia es insuficiente?	Casos de baja confianza, abstención o advertencias.
Explicabilidad	¿Puede justificarse la salida en relación con la evidencia multimodal?	Evidencia visual, textual o estructurada asociada a la respuesta.

Dimensión	Pregunta orientadora	Evidencia esperada en MCC225
Robustez	¿El sistema mantiene comportamiento razonable ante ruido, cambios de prompt o cambios de dominio?	Evaluaciones con perturbaciones y análisis de sensibilidad.
Alucinación	¿El sistema inventa objetos, relaciones, fuentes o hechos no presentes?	Matriz de errores, casos fallidos y severidad.
Gobernanza	¿Hay roles, políticas, logs, revisión y monitoreo?	Checklist de documentación, trazabilidad y control de cambios.

6. Explicabilidad e interpretabilidad en MLLMs

6.1. Diferencia entre explicar e interpretar

En modelos multimodales grandes, **explicabilidad** e **interpretabilidad** no son sinónimos exactos. La explicabilidad suele referirse a mecanismos que ayudan al usuario o evaluador a entender por qué el sistema produjo una salida: regiones de imagen atendidas, fragmentos textuales usados, pasos de razonamiento, evidencia recuperada o justificaciones en lenguaje natural. La interpretabilidad apunta con mayor fuerza a entender mecanismos internos del modelo: representaciones, capas, cabezas de atención, activaciones, circuitos, embeddings o componentes causales.

Explainable and Interpretable Multimodal Large Language Models: A Comprehensive Survey organiza este problema desde tres perspectivas: datos, modelo, y entrenamiento e inferencia. Esta separación es útil para MCC225 porque evita tratar la explicación como una figura decorativa. Una explicación puede estar asociada a la curación de datos, al análisis de arquitectura o al control de la generación en inferencia.

6.2. Explicabilidad de datos

La explicabilidad de datos pregunta qué patrones, sesgos, fuentes, etiquetas, captions, anotaciones y distribuciones influyen en el comportamiento del modelo. En multimodalidad, este punto es crucial porque un dataset puede contener desbalances visuales, textuales o culturales. También puede incluir captions ruidosos, imágenes ambiguas, OCR deficiente o asociaciones espurias entre objetos y etiquetas.

En un proyecto de MCC225, una explicación basada en datos debería indicar:

- de dónde provienen las imágenes, textos o videos,
- qué criterios de filtrado se aplicaron,
- qué clases o categorías están sobrerrepresentadas,
- qué subgrupos o contextos están ausentes,
- qué anotaciones podrían inducir sesgo,
- qué ejemplos son ambiguos o de baja calidad.

6.3. Explicabilidad del modelo

La explicabilidad del modelo examina componentes internos. En VLMs y MLLMs puede incluir mapas de atención, análisis de embeddings, comparación de capas, activaciones, atribución

visual-textual o estudios de causalidad interna. Sin embargo, debe evitarse una conclusión ingenua: un mapa de atención no prueba automáticamente que el modelo haya razonado correctamente. Puede ser una señal útil, pero no una explicación causal completa.

Por ello, en MCC225 se debe exigir que toda explicación visual o textual responda al menos tres preguntas:

1. ¿Qué evidencia muestra?
2. ¿Qué afirmación permite sostener?
3. ¿Qué afirmación no permite sostener?

6.4. Explicabilidad en inferencia

La explicabilidad en inferencia busca que la salida del sistema sea verificable. En un sistema de VQA, por ejemplo, no basta responder “sí” o “no”. Puede requerirse indicar qué región visual, qué texto de la imagen, qué dato recuperado o qué regla permitió responder. En un sistema RAG multimodal, la explicación debe incluir evidencia recuperada y relación explícita entre evidencia y respuesta.

7. Sesgo y fairness en sistemas multimodales

7.1. Qué significa sesgo en multimodalidad

El sesgo en sistemas multimodales puede surgir por datos no representativos, anotaciones defectuosas, modelos base entrenados con contenido web, prompts mal diseñados, categorías culturales restringidas o métricas que ocultan diferencias entre subgrupos. En multimodalidad el problema se agrava porque el sesgo puede entrar por más de una vía: imagen, texto, audio, metadatos, etiqueta, prompt o contexto de uso.

Un sistema puede ser sesgado aunque el promedio global sea alto. Por ejemplo, puede describir mejor ciertos tipos de escenas, rostros, lenguas, regiones, dispositivos médicos, estilos gráficos o contextos educativos. También puede heredar sesgos del encoder visual o del modelo lingüístico, y amplificarlos durante la generación.

7.2. FMBench como caso de alto impacto

FMBench: Benchmarking Fairness in Multimodal Large Language Models on Medical Tasks es un caso especialmente útil porque evalúa fairness en tareas médicas multimodales. El paper considera atributos demográficos como raza, etnicidad, idioma y género, y trabaja con tareas como VQA y generación de reportes. Además, propone evaluar no solo exactitud lingüística, sino también dimensiones alineadas con evaluación clínica.

Para MCC225, FMBench cumple una función metodológica: muestra que la equidad no se puede reducir a una métrica global. Debe analizarse por atributos, tareas, tipos de error y severidad. En dominios de alto impacto, una diferencia pequeña en promedio puede ser grave si afecta sistemáticamente a un grupo o si el error tiene consecuencias clínicas, legales o educativas.

7.3. Métricas de fairness

Una evaluación mínima de fairness puede incluir:

- desempeño global,
- desempeño por subgrupo,
- brecha máxima entre subgrupos,
- dispersión del desempeño,

- severidad cualitativa de errores,
- estabilidad frente a prompts equivalentes,
- análisis de errores representativos.

En proyectos pequeños, el estudiante no siempre tendrá datos suficientes para una evaluación estadística robusta. Aun así, debe declarar esa limitación y realizar una exploración cualitativa honesta. La ausencia de evidencia no debe presentarse como evidencia de ausencia de sesgo.

8. Confianza multimodal: verdad, robustez, seguridad, fairness y privacidad

8.1. El problema de la confianza multimodal

Unveiling Trust in Multimodal Large Language Models: Evaluation, Analysis, and Mitigation propone estudiar la confianza en MLLMs considerando varias dimensiones: veracidad, robustez, seguridad, fairness y privacidad. Su aporte para MCC225 es que no separa los riesgos multimodales como si fueran simples extensiones de riesgos textuales. La multimodalidad introduce riesgos propios: una imagen puede inducir una respuesta falsa, un texto puede contradecir la imagen, una modalidad puede dominar indebidamente a otra o una señal visual puede activar un comportamiento inseguro.

Esta idea es importante para proyectos de clase. Un estudiante puede evaluar un modelo con prompts textuales limpios, pero el sistema real puede recibir imágenes con ruido, texto embebido, documentos complejos, screenshots o entradas adversariales. La confianza debe evaluarse en el cruce entre modalidades.

8.2. Riesgos cross-modal

Un riesgo cross-modal aparece cuando la interacción entre modalidades produce una falla que no se observaría analizando cada modalidad por separado. Algunos ejemplos académicamente relevantes son:

- una imagen contradice el texto y el modelo sigue el texto sin revisar la evidencia visual,
- una pregunta induce al modelo a afirmar objetos no presentes,
- un OCR incorrecto altera la respuesta final,
- una imagen ambigua genera una justificación textual excesivamente segura,
- un prompt aparentemente inocuo cambia el nivel de cautela del sistema.

La mitigación puede actuar en datos, arquitectura, entrenamiento o inferencia. Sin embargo, toda mitigación debe evaluarse nuevamente porque puede introducir trade-offs: más seguridad puede reducir utilidad; más abstención puede bajar cobertura; más explicación puede aumentar confianza injustificada si la explicación no es fiel.

9. NIST AI RMF Generative AI Profile

9.1. Gestión de riesgos para IA generativa

El *NIST AI RMF Generative AI Profile* es una guía transversal para gestionar riesgos de IA generativa. Funciona como un perfil del AI Risk Management Framework y organiza acciones alrededor de gobernar, mapear, medir y gestionar riesgos. Para MCC225, su valor está en convertir preocupaciones generales en prácticas documentables durante el ciclo de vida del sistema.

El documento identifica riesgos que pueden ser nuevos o exacerbados por IA generativa, incluyendo confabulación, privacidad de datos, sesgo dañino, integridad de información, seguridad

de información, propiedad intelectual, integración de componentes de la cadena de valor e impactos ambientales. En esta lectura, estos riesgos se reinterpretan para sistemas multimodales: no solo importa qué texto genera el sistema, sino qué evidencia visual o textual usa, cómo la mezcla y qué tan verificable es la salida.

9.2. Funciones del marco

Tabla 3: Lectura operativa del NIST AI RMF para MCC225

Función	Pregunta	Aplicación en un proyecto multimodal
Gobernar	¿Quién define políticas, roles, límites y responsabilidades?	Definir alcance, responsables, restricciones de uso y criterio de revisión humana.
Mapear	¿Qué contexto, actores, datos y riesgos existen?	Identificar usuarios, tareas, modalidades, datos sensibles, subgrupos y posibles fallas.
Medir	¿Cómo se cuantifican o inspeccionan riesgos?	Usar métricas por tarea, análisis de error, pruebas adversariales y evaluación por subgrupo.
Gestionar	¿Qué controles reducen o monitorean riesgos?	Incorporar filtros, documentación, abstención, logs, curación de datos y monitoreo.

10. OECD AI Principles

10.1. Principios para IA confiable

Los *OECD AI Principles* proporcionan una base internacional para IA confiable. En términos educativos, su valor es que conectan la evaluación técnica con valores democráticos, derechos humanos, transparencia, robustez, seguridad y rendición de cuentas. Para un curso como MCC225, esto ayuda a evitar que el proyecto final se reduzca a una comparación de métricas sin reflexión sobre consecuencias.

Una adaptación práctica para MCC225 puede expresarse así:

1. el sistema debe tener un propósito legítimo y claramente delimitado,
2. los datos y resultados deben documentarse con transparencia razonable,
3. los errores y limitaciones deben comunicarse sin exagerar capacidades,
4. la robustez debe evaluarse frente a cambios de entrada y contexto,
5. debe existir responsabilidad humana sobre decisiones y despliegue,
6. se debe evitar daño desproporcionado sobre grupos o contextos específicos.

11. ISO/IEC 42001:2023 y sistema de gestión de IA

11.1. De buenas intenciones a sistema de gestión

ISO/IEC 42001:2023 es un estándar de sistema de gestión de inteligencia artificial. Su enfoque no consiste solo en medir un modelo, sino en establecer, implementar, mantener y mejorar un sistema organizacional para gestionar IA. Para MCC225, esto puede parecer más institucional que técnico, pero resulta útil porque introduce una idea clave: la IA responsable necesita procesos,

roles, documentación, revisión y mejora continua.

Un estudiante no necesita implementar el estándar completo. Sin embargo, puede tomar de él una lógica de trabajo:

- definir contexto y alcance del sistema,
- identificar partes interesadas,
- asignar responsabilidades,
- evaluar riesgos e impactos,
- documentar datos y decisiones,
- monitorear desempeño,
- registrar incidentes y cambios,
- mejorar el sistema a partir de evidencia.

11.2. Aplicación a trabajos integradores

En un trabajo integrador de MCC225, una versión académica de esta lógica puede incluir una ficha de gobernanza del proyecto. No se trata de burocratizar el trabajo, sino de hacer explícitas las decisiones que afectan confiabilidad.

Listing 1: Ficha mínima de gobernanza para un proyecto multimodal

```

proyecto: nombre_del_sistema
propósito: tarea y dominio permitidos
usuarios_previstos: estudiantes, docentes, evaluadores u otros
modalidades: texto, imagen, audio, video
datos: fuente, licencia, filtrado, anonimización
riesgos_principales: alucinación, sesgo, privacidad, error de OCR, error visual
supervisión_humana: cuándo interviene una persona
métricas: desempeño, robustez, fairness, errores cualitativos
limitaciones: lo que el sistema no debe afirmar ni hacer
monitoreo: logs, ejemplos fallidos, revisión posterior

```

12. EU AI Act 2024/1689

12.1. Enfoque basado en riesgo

El *EU AI Act 2024/1689* establece un marco regulatorio basado en riesgo para sistemas de inteligencia artificial. Aunque MCC225 no es un curso de derecho, este marco es útil porque formaliza preocupaciones relevantes para ingeniería: documentación técnica, transparencia, supervisión humana, gestión de riesgos, calidad de datos, trazabilidad y obligaciones diferenciadas según el nivel de riesgo.

Para el trabajo académico, la lectura principal no debe ser legalista. Debe ser metodológica: cuanto mayor sea el impacto potencial del sistema, mayor debe ser la evidencia exigida. Un prototipo de recuperación de imágenes educativas puede tener un umbral de riesgo distinto al de un sistema que asiste decisiones médicas o administrativas. La conclusión experimental debe reflejar esa diferencia.

12.2. Traducción pedagógica

En MCC225, el enfoque basado en riesgo puede traducirse en cuatro preguntas:

1. ¿Qué daño podría producir una salida incorrecta?
2. ¿Quién sería afectado por ese error?

3. ¿El usuario puede detectar la falla sin conocimiento experto?
4. ¿Qué documentación y supervisión serían necesarias antes de usar el sistema fuera del laboratorio?

13. Pipeline responsable para proyectos multimodales

13.1. Fase 1: definición de alcance

Antes de evaluar, debe definirse qué hace el sistema y qué no hace. Esta fase evita afirmaciones vagas como “el modelo entiende imágenes”. Una formulación más rigurosa sería: “el sistema responde preguntas visuales simples sobre un subconjunto de imágenes educativas en español, con evaluación manual de errores de OCR, conteo y relaciones espaciales”.

13.2. Fase 2: documentación de datos

La documentación de datos debe indicar origen, licencia, tamaño, particiones, criterios de filtrado, idiomas, subgrupos visibles, limitaciones y posibles sesgos. En multimodalidad también debe incluir calidad visual, resolución, presencia de texto incrustado, ruido, duplicados y ambigüedad.

13.3. Fase 3: evaluación de desempeño

La evaluación debe usar métricas coherentes con la tarea. Para VQA puede usarse exactitud normalizada, exactitud por tipo de pregunta y revisión cualitativa. Para captioning pueden usarse métricas automáticas con cautela y evaluación humana. Para retrieval pueden usarse Recall@K, MRR y análisis de negativos duros.

13.4. Fase 4: evaluación de confiabilidad

La confiabilidad requiere pruebas adicionales:

- robustez ante ruido visual o textual,
- sensibilidad a prompts equivalentes,
- desempeño por subgrupo o categoría,
- detección de alucinaciones,
- casos de incertidumbre,
- fallas por OCR, grounding o razonamiento espacial,
- evaluación de privacidad y datos sensibles.

13.5. Fase 5: mitigación y reevaluación

Una mitigación solo tiene valor si se evalúa. Si se agregan filtros, prompts de cautela, recuperación externa, abstención o reglas de seguridad, debe medirse el efecto sobre desempeño, cobertura, falsos rechazos, utilidad y errores restantes. La mitigación no debe presentarse como solución definitiva si solo fue probada en pocos ejemplos.

14. Matriz de riesgos para MCC225

Tabla 4: Matriz de riesgos para sistemas multimodales de clase

Riesgo	Cómo aparece	Evidencia mínima	Mitigación inicial
Alucinación visual	El sistema afirma objetos, textos o relaciones no presentes.	Casos fallidos, tasa aproximada y severidad.	Prompt de cautela, verificación, abstención.
Sesgo de datos	El sistema funciona peor en ciertos grupos, estilos o idiomas.	Resultados por categoría o subgrupo.	Curación de datos, balanceo, reporte de límites.
Error de OCR	La respuesta depende de texto mal leído en la imagen.	Ejemplos con texto incrustado y errores.	Mejor OCR, segmentación, revisión humana.
Sobreconfianza	El sistema responde con seguridad pese a evidencia insuficiente.	Casos de incertidumbre no comunicada.	Salidas calibradas, opción “no sé”.
Privacidad	Entrada o salida contiene información sensible.	Revisión de datos y ejemplos.	Anonimización, filtrado, restricciones.
Robustez baja	Pequeños cambios alteran la respuesta.	Pruebas con prompts equivalentes o ruido.	Evaluación aumentada, prompts estables.
Explicación infiel	La justificación no corresponde a la causa real o evidencia.	Comparación entre salida y evidencia.	Evidencia explícita, trazabilidad.
Uso indebido	El sistema se aplica fuera de su alcance.	Análisis de escenarios no permitidos.	Declaración de uso, límites y supervisión.

15. Criterios mínimos de calidad responsable

15.1. Criterio 1: alcance explícito

Todo informe debe indicar el dominio, las tareas, las modalidades y los casos no cubiertos. Si el sistema fue probado solo en un subconjunto pequeño, la conclusión debe limitarse a ese subconjunto.

15.2. Criterio 2: evidencia separada por dimensión

No se debe mezclar desempeño, fairness, explicabilidad y robustez en una afirmación global. Cada dimensión requiere evidencia propia. Una tabla final puede resumir el estado de cada dimensión, pero no reemplaza el análisis.

15.3. Criterio 3: análisis de error con severidad

No basta decir que hubo errores. Debe indicarse el tipo de error, la modalidad afectada, la causa probable, la severidad y una posible mitigación. En sistemas multimodales, el error puede venir de percepción, OCR, recuperación, razonamiento, prompt, datos o generación.

15.4. Criterio 4: limitaciones no decorativas

Una limitación no debe ser una frase genérica al final. Debe alterar la interpretación de resultados. Por ejemplo, “no se evaluó en imágenes con texto pequeño” implica que no se puede afirmar confiabilidad para documentos visuales con OCR complejo.

15.5. Criterio 5: trazabilidad

El informe debe permitir reconstruir qué modelo, datos, prompts, configuración, métricas y ejemplos se usaron. Sin trazabilidad, no hay reproducibilidad ni responsabilidad.

16. Checklist para el informe del estudiante

Listing 2: Checklist de confiabilidad, sesgo, explicabilidad y uso responsable

- [] El propósito del sistema está definido.
- [] El alcance y los usos no permitidos están declarados.
- [] Las fuentes de datos están documentadas.
- [] Existen métricas de desempeño acordes con la tarea.
- [] Hay análisis de errores por categoría.
- [] Se revisan fallas de alucinación o confabulación.
- [] Se evalúa robustez ante cambios de prompt o entrada.
- [] Se discute sesgo o cobertura de subgrupos.
- [] Se incluye evidencia de explicabilidad o trazabilidad.
- [] Se revisa privacidad y posible exposición de datos sensibles.
- [] Se declaran limitaciones reales.
- [] La conclusión no excede la evidencia experimental.

17. Errores conceptuales frecuentes

17.1. Confundir desempeño con confiabilidad

Una métrica alta no prueba que el sistema sea confiable. Solo indica buen desempeño bajo una configuración de evaluación. La confiabilidad exige analizar fallas, severidad, contexto, sesgo, robustez y supervisión.

17.2. Usar explicaciones como decoración

Un mapa de atención, una región resaltada o una justificación textual no son suficientes si no se demuestra que están vinculados con la salida. Una explicación debe ser verificable y debe reconocer sus límites.

17.3. Declarar que no hay sesgo sin medirlo

No encontrar evidencia de sesgo en pocos ejemplos no significa que el sistema sea justo. Una afirmación responsable diría: “no se realizó una evaluación estadística completa de fairness; se presentan indicios cualitativos y se recomienda ampliar la muestra”.

17.4. Tratar la regulación como un anexo irrelevante

Los marcos de gobernanza y regulación no sustituyen la experimentación, pero ayudan a definir qué se debe documentar, qué riesgos considerar y qué responsabilidades no pueden delegarse al modelo.

18. Propuesta de actividad para la Semana 9

18.1. Objetivo

El estudiante debe tomar un sistema multimodal evaluado previamente y producir una ficha de confiabilidad responsable. La ficha debe conectar desempeño, análisis de error, sesgo, explicabilidad, privacidad, robustez y límites de uso.

18.2. Entregables

1. descripción del sistema y su alcance,
2. resumen de métricas disponibles,
3. matriz de riesgos,
4. diez errores cualitativos clasificados,
5. análisis de sesgo o cobertura,
6. evidencia de explicabilidad o trazabilidad,
7. discusión de privacidad y seguridad,
8. conclusión responsable.

18.3. Criterio de aprobación

La actividad no se aprueba por afirmar que el sistema es bueno, sino por demostrar que el estudiante entiende qué evidencia tiene, qué evidencia falta, qué riesgos son relevantes y qué afirmaciones serían metodológicamente indebidas.

19. Relación con el trabajo integrador

En el trabajo integrador de MCC225, la Semana 9 debe aparecer como una sección explícita del informe final. Una estructura mínima puede ser:

1. descripción del modelo o sistema,
2. evaluación cuantitativa,
3. análisis cualitativo de errores,
4. confiabilidad y robustez,
5. sesgo y cobertura de datos,
6. explicabilidad y trazabilidad,
7. privacidad y uso responsable,
8. limitaciones y trabajo futuro.

Esta estructura obliga a que la conclusión no dependa únicamente de resultados exitosos. También ayuda a defender el proyecto en exposición, porque anticipa preguntas sobre fallas, riesgos, reproducibilidad y alcance.

20. Conclusión

La confiabilidad de un sistema multimodal no se demuestra con una demostración vistosa ni con una métrica aislada. Se construye mediante evaluación rigurosa, análisis de error, documentación de datos, revisión de sesgos, trazabilidad, pruebas de robustez, explicación verificable y comunicación honesta de limitaciones.

Los papers y marcos revisados en esta lectura muestran que la IA multimodal responsable requiere integrar investigación técnica y gobernanza. *Reliable and Responsible Foundation Models*

ofrece una visión amplia de riesgos y responsabilidades. *Explainable and Interpretable MLLMs* ayuda a estructurar la explicación e interpretación. *FMBench* muestra cómo evaluar fairness en un dominio de alto impacto. *Unveiling Trust in MLLMs* organiza la confianza multimodal en dimensiones técnicas y riesgos cross-modal. NIST, OECD, ISO/IEC 42001 y el EU AI Act trasladan estas preocupaciones hacia prácticas de gestión, documentación y responsabilidad.

Para MCC225, la conclusión metodológica es directa: un proyecto multimodal de calidad no solo debe funcionar; debe explicar dónde funciona, dónde falla, por qué podría fallar, a quién podría afectar y qué evidencia respalda cada afirmación.

A. Glosario breve

Confiabilidad	Capacidad de un sistema para comportarse de manera adecuada dentro de un alcance, una tarea y un contexto definidos.
Sesgo	Diferencia sistemática de comportamiento asociada a datos, subgrupos, categorías, contextos, prompts o modalidades.
Fairness	Evaluación de equidad del sistema respecto a grupos, atributos o condiciones relevantes para el dominio.
Explicabilidad	Capacidad de ofrecer razones, evidencia o trazabilidad comprensible sobre una salida.
Interpretabilidad	Comprensión de mecanismos internos del modelo, como representaciones, capas, activaciones o circuitos.
Confabulación	Producción de contenido falso, inventado o no respaldado por la evidencia, presentado con apariencia de certeza.
Grounding	Relación verificable entre la salida del sistema y la evidencia disponible en la entrada o en fuentes recuperadas.
Robustez	Estabilidad del comportamiento frente a perturbaciones, ruido, cambios de prompt o cambios de distribución.
Privacidad	Protección de información sensible en datos de entrada, entrenamiento, inferencia, logs y salidas.
Gobernanza	Conjunto de políticas, roles, procesos, documentación y controles para dirigir y supervisar sistemas de IA.

B. Referencias

1. X. Yang et al. *Reliable and Responsible Foundation Models: A Comprehensive Survey*. arXiv:2602.08145, 2026. <https://arxiv.org/abs/2602.08145>
2. Y. Dang et al. *Explainable and Interpretable Multimodal Large Language Models: A Comprehensive Survey*. arXiv:2412.02104, 2024. <https://arxiv.org/abs/2412.02104>
3. P. Wu et al. *FMBench: Benchmarking Fairness in Multimodal Large Language Models on Medical Tasks*. arXiv:2410.01089, 2024. <https://arxiv.org/abs/2410.01089>
4. Y. Zhang et al. *Unveiling Trust in Multimodal Large Language Models: Evaluation, Analysis, and Mitigation*. arXiv:2508.15370, 2025. <https://arxiv.org/abs/2508.15370>
5. National Institute of Standards and Technology. *Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile*. NIST AI 600-1, 2024. <https://doi.org/10.6028/NIST.AI.600-1>

6. OECD. *OECD AI Principles*. <https://www.oecd.org/en/topics/sub-issues/ai-principles.html>
7. ISO. *ISO/IEC 42001:2023: Information technology - Artificial intelligence - Management system*. <https://www.iso.org/standard/42001>
8. European Parliament and Council of the European Union. *Regulation (EU) 2024/1689*. Official Journal of the European Union, 2024. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>